Contents

小项目实施指南：面试弹药库（v4 重写版） **1**
0. 通用要求（保留 v3 不变） 1
1. 互补全景图（v4 新增，先读这一节再看每个项目） 1
2. S1 mini-Raft KV（必做，3-4 周硬顶） 3
3. S2 C++/io_uring 预取器（并入 P1，不占独立名额） 4
4. S3 eBPF 观测工具（可选，后置，MVP 砍到只剩一个探针） 5
5. S4 bitcask mini 存储引擎（v4：聚焦 WAL/merge/crash recovery，与 P1 正交） 6
6. S6 K8s 调度插件实战：拓扑感知打分（v4：砍阶段 B，聚焦 NFD/topology-updater/拓扑亲和） . 7
7. S7 mini KV Cache Manager（v4 新增，P2 互补） 9
8. 微弹药 M1-M5（按天计的练手小品，算不上项目） 11
9. 微弹药与面试域的关系（v4 扩展） 13

小项目实施指南：面试弹药库（v4 重写版）

2026-10-15 v4 重写 + v4.1 砍 S8（导师与学员讨论定稿）：核心变化是**从”二选一”改为”互补而非巩固”**——重新定义 S4 和 S6 的 scope 让它们覆盖 P1/P2 的空白域而非重叠域；新增 S7/M4/M5 补 P2 的引擎内核空白；v4.1 砍掉 S8（模拟器产出在面试里天然比真实系统低一档，且互补价值已被 S7/M5 覆盖）。定位铁律不变：小项目不写进简历，用途只有两个——充当面试弹药，以及给大项目提前扫雷。评价标准只有一条：单位时间内能产出多少面试弹药。

0. 通用要求（保留 v3 不变）

1. 每个项目都要有独立仓库和 README（写清设计取舍、实验数据、复现命令）；代码是写给你自己看的，真正的弹药是 README 和实验记录；
2. 每个项目都必须攒齐”弹药三件套”：一个设计取舍、一个亲自踩过的坑、一张数据或对照表；
3. 硬性时间盒：每个项目开工之前，你要在 README 顶部写下截止日期；超期了就砍功能，不能砍质量，更不许对自己说”再打磨一周”；
4. 弹药纪律：项目做完之后立刻写一页《复盘卡》（如果重来会怎么改、被追问时最薄弱的三个点），面试之前你只需要看这张卡；
5. 名额纪律（v4 修改）：**独立占用工期的小项目可以全做**（S1 + S2 + S3 + S4 + S6 + S7），不做”二选一”；但必须遵守互补原则——每个项目只做大项目没覆盖的空白域，不重复；
6. 微弹药 M1-M5（v4 新增 M4/M5）：按天计的练手小品，算不上项目、不写进简历、不占名额，总投入不超过 1 周。

1. 互补全景图（v4 新增，先读这一节再看每个项目）

这一节列出 P1/P2 覆盖了什么、没覆盖什么，每个小项目补的是哪块空白。这是 v4 重写的核心决策依据。

P1 TrainCache 覆盖的能力域

能力域	P1 实现方式	小项目补什么
存储数据面	CAS 内容摘要 + 驱逐 + P2P + **重扫描恢复**	S4 补 **WAL + merge + WAL replay 恢复**（和 P1 的重扫描正交）
K8s 调度	**数据亲和**（前缀就绪度门控 + 打分 + SchedulingGate）	S6 补 **拓扑亲和**（NFD/topology-updater/NUMA/GPU zone）

能力域	P1 实现方式	小项目补什么
Agent 观测	**用户态**（inotify + /metrics）	S3 补 **内核级**（eBPF tracepoint + block I/O 直方图）
容器数据面	hostPath 只读挂载（preheat 模型）	M3 补 **CSI 标准 API**（NodePublishVolume/bind mount）
分布式共识	用 etcd（不自研 Raft）	S1 补 **自研 Raft**（选举/复制/快照/崩溃恢复）

P2 KVRouter 覆盖的能力域

能力域	P2 实现方式	小项目补什么
KV cache 视角	**网关视角**（消费 vLLM 推的 KV 事件）	S7 补 **引擎内核视角**（精读 block_manager.cpp + 写简化版）
推理调度	消费已完成调度的结果（continuous batching 在 vLLM 内核里）	M5 补 **精读 scheduler**（continuous batching / preemption 调度逻辑）
观测粒度	**粗粒度**（vLLM /metrics 的 TTFT/TBT/吞吐）	M4 补 **token 级**（eBPF uprobes 精确到每个 token 的 prefill/decode 时间）
引擎源码理解	消费 AIBrix 路由层源码	S7 + M5 补 **引擎内核精读**（block_manager + scheduler + attention）

小项目编号与互补关系总表

项目	大项目没覆盖什么	小项目补什么	互补类型	Scope 变化
S1 mini-Raft KV	P1 用 etcd 不自研；P2 单机网关	分布式共识：选举、日志复制、快照、崩溃恢复	全新互补	**不动**
S2 io_uring 预取器	P1/P2 主力 Go，无 C++ 系统编程	C++ 系统编程：io_uring、O_DIRECT、aligned memory	全新互补	**不动**（已并入 P1）
S3 eBPF 观测工具	P1 只有用户态 inotify；P2 只有网关级 metrics	eBPF 内核级观测：block I/O 直方图、major fault、readahead 归因陷阱	全新互补	**不动**
S4 bitcask mini	P1 用 CAS + **重扫描**做 crash recovery（重启 ~ 分钟级）、不做 WAL、不做 merge	**WAL 持久化 + merge + WAL replay 恢复**（重启 ~ 秒级）、fsync 三档对比、10M key 内存账	正交互补	**修改**：砍掉和 P1 重合的 CAS/refcount，聚焦 WAL/merge/crash recovery

项目	大项目没覆盖什么	小项目补什么	互补类型	Scope 变化
S6 K8s 调度插件	P1 步骤 7 只做 **数据亲和**（前缀就绪度）；**没有** NFD/topology-updater/拓扑约束	**拓扑亲和**：NFD + topology-updater + 官方 NRT 插件、NUMA/GPU zone 过滤与打分	正交互补	**修改**：砍掉阶段 B（自研最小插件，和 P1 步骤 7 重复），保留阶段 A + C
S7 mini KV Cache Manager（v4 新增）	P2 把 vLLM 当黑盒；不自研 KV block 管理；不做引擎内核	C++ 写简化版 block manager：固定大小 KV pool、LRU 驱逐、prefix lookup、capacity 动态调整	全新互补	**新增**
M1 mini-container	大项目只用 K8s API，不碰容器底层	namespace/cgroup/pivot_root/overlayfs 可写层	全新互补	**不动**
M2 mini-CNI	大项目只管容器调度和挂载，不管 Pod 网络	bridge/veth/地址池/路由/ipvs	全新互补	**不动**
M3 mini-CSI	P1 用 hostPath，没走标准 K8s 存储 API	CSI Node 端、kubelet registration、bind mount	全新互补	**不动**
M4 vLLM token 级 profiling（v4 新增）	P2 只有粗粒度 /metrics	eBPF uprobes 精确到每个 token 的 prefill/decode 时间	全新互补	**新增**
M5 vLLM 引擎源码精读笔记（v4 新增）	P2 消费路由层源码，没读引擎内核	精读 block_manager + scheduler + attention，产出对读笔记	全新互补	**新增**

---

2. S1 mini-Raft KV（必做，3-4 周硬顶）

互补关系：P1 用 etcd（不自研 Raft）、P2 是单机网关——S1 补的是分布式共识的工程经验，这是大项目都不覆盖的能力域。

介绍：用 Go 实现一个 3 节点的 Raft，对外暴露 Get/Put 接口。做这个项目的目的，是把一致性从”背出来的知识点”变成”能讲清楚的东西”。你要保持清醒：这是 MIT 6.824 里人手一个的项目，实现本身的差异化几乎为零，简历上永远不要把它排在第一位；它的弹药价值全在工程细节、实验设计和工业代码对读里。

范围：做选举、日志复制、快照、崩溃恢复；不做：membership 变更、Pre-Vote（这两个列为”你必须能在白板上讲清楚”的内容）。

关键设计（保留 v2）

- 状态机三个角色，用一个单 tick 驱动所有定时器（time.Timer 的超时时间在 [T, 2T) 内随机化，T 大约取 500ms）；

- 有三个字段必须持久化：`currentTerm`、`votedFor`、`log[]`——这是一个经典的死亡陷阱：`votedFor` 不落盘，节点就可能在同一个任期里投出两票，进而脑裂。WAL 的记录格式是 `len | crc32 | entry`，采用追加写；
- RPC (gRPC) 包括 `RequestVote` 和 `AppendEntries`：收到每个回复都先比 term，发现自己的 term 更小就立刻让位——这是第二大陷阱；
- 提交规则：leader 只能提交当前任期的日志（对应 §5.4.2）；prevLogIndex/term 不匹配时回退 nextIndex，如果你实现了冲突项的加速回退，这是加分项；
- 线性一致读（stretch 目标）：用 ReadIndex 或走日志的方式实现；你要能讲清楚”为什么 ReadIndex 对时钟的依赖比 lease 小”；
- 快照：在 `lastIncludedIndex` 之前截断日志，配合 `InstallSnapshot` 传输；恢复时先装快照，再重放后续日志。

v3 增强（三个动作，把弹药从 60 分提到 85 分）

1. **工业对读（必做）**：toy 版本跑通之后，精读 etcd 的 raft 库——重点看 `node.go` 里的 Ready 循环、unstable log、Storage 接口，以及 ReadIndex 的工业实现。最后产出一篇《我的 toy raft 与 etcd raft 的 5 个差异》(候选差异：批量化的 Ready 通道、消息流水线、leader 转移、检查点时机、无环日志结构)。“写过一个 lab”和”写过 lab 还读过工业实现”的人，在面试里完全是两个物种；
2. **实验一换血**：删掉”30% 丢包单点”这个老实验（它太极端了，只能得到”它瘫了”这一个结论），改为丢包率扫描 0.1% / 1% / 5% / 10%，画出 commit P50/P99 随丢包率变化的曲线，并解释曲线的拐点（重传与选举超时是如何耦合的）；
3. **实验二为新增内容**：无主停机窗口的分布——`kill -9` leader 至少 100 次，记录从 kill 发生到新 leader 完成第一个成功写入的时间分布（中位数/P99)。这是一个比提交延迟更受分布式面试官看重的可用性数字。分区实验要区分三种：多数派隔离、少数派隔离、不对称分区（leader 单向失联），分别给出行为表。

实施步骤

1. 单机 KV 加 WAL；2. 搭 gRPC 骨架和选举（打印每次 term 变化和投票流向）；3. 复制与提交（把 raftd 集成进测试 harness，注入延迟、分区和重启）；4. 快照和 `kill -9` 恢复；5. 完成 v3 的两组实验，写 etcd 对读笔记。

验收标准：故障注入下，已经提交的数据零丢失；三类分区的行为表完整；丢包扫描曲线画出来；无主窗口分布有至少 100 个样本；etcd 差异笔记写完。

你能讲的点：`votedFor` 为什么必须持久化；为什么只能提交当前任期的日志；ReadIndex 与 Lease 的对比；你的 toy 实现与 etcd 的具体差异；Pre-Vote 如何防止分区节点拿着旧 term 扰乱选举；joint consensus 两阶段成员变更（不要求实现，但要能白板讲)。

---

3. S2 C++/io_uring 预取器（并入 P1，不占独立名额）

互补关系：P1/P2 主力 Go，无 C++ 系统编程——S2 补的是 C++ + io_uring + O_DIRECT + aligned memory 这套系统级硬货。同时是 vLLM C++ 源码精读的前置训练（S7/M5 需要读 vLLM 的 C++ 代码，S2 先让你熟悉 C++ 系统编程的坑)。

定位：P1 §9.2 A 轨（小文件高 IOPS 臂）的实验分支。可以为它单独建仓库，但不占小项目名额，也不另排独立工期，随 P1 步骤 8 前后推进即可。

范围：做本地写路径和提交模型；不做：完整的 S3 客户端（HTTP Range 已经够用)。

关键设计（保留 v2）

- io_uring (liburing)：队列深度在 64–256 之间可配；用 `IORING_REGISTER_FILES` 加 registered buffer 消掉每个 op 的固定开销；
- O_DIRECT 三重对齐的坑：缓冲区地址、长度、偏移都必须对齐逻辑块（用 `posix_memalign` 对齐到 4K）；
- overlayfs 的坑：在容器里的 overlayfs 上用 O_DIRECT，可能直接报 EINVAL——目标路径必须落在宿主机真实的 ext4/xfs 上（用 hostPath，或者干脆在宿主机上直接跑）；
- 提交与收割：`get_sqe → prep → submit_and_wait(N)`，CQE 批量收割之后再 resubmit，错误码逐个处理（短读即 EOF）；
- 用 fio 校准：先测出裸盘直写的上限，然后贴着这个上限比，“我比 fio 差 8%”这种说法比”我很快”专业十倍。

v3 补强

- 步骤 0 先 `uname -r` 锁定内核版本（registered files/buffers 的行为会随版本变化），并且把 liburing 官方 examples 逐个通关——io_uring、O_DIRECT、overlayfs 三个坑叠加在一起，直接上手太陡了，而 C++ 是你的次语言，这个坡度必须削平；
- 收益预期要预先诚实化：P1 主臂的 4MiB 块经 HTTP 抓取时受网络限速，本地写路径省下的 syscall 对吞吐的贡献预期接近于零；io_uring 真正的战场是 A 轨的小文件高 IOPS。报告里正确的写法是”syscall 数量大幅下降、大块吞吐不变（并解释为什么受网络限速）、小文件臂 IOPS 提升 X”，不许只挑好看的数字报。

实施步骤

1. Go 线程池加 buffered 基线 → 2. C++ buffered 版本（隔离语言因素）→ 3. O_DIRECT 加 io_uring → 4. registered 优化版 → 5. 跑参数矩阵（QD × 块大小 4K/64K/1M × 并发，记录吞吐、strace 统计的 syscall 数、CPU 占用）。

弹药：O_DIRECT 对齐与 overlayfs 的坑；io_uring 到底减少了什么（syscall 加线程调度）；为什么大块场景下它赚不到收益——能把”不适用的边界”讲清楚，比吹收益值钱得多。

---

4. S3 eBPF 观测工具（可选，后置，MVP 砍到只剩一个探针）

互补关系：P1 用 **用户态 inotify** 观测、P2 用 vLLM /metrics 观测——S3 补的是 **内核级** 观测，能看到用户态看不到的东西（比如 readahead 造成的 major fault 不会记在消费者进程名下，按进程维度归因就会算错）。

定位：后移到 P1 核心 1 完工之后，有余力了再做；MVP 只做一个探针，不做全家桶。

范围：只做只读观测；要求内核版本不低于 5.10；在宿主机上跑（容器权限很麻烦，先在宿主机上做）。

v3 范围

- **MVP（唯一必做项）**：block I/O 延迟直方图——用 tracepoint `block/block_rq_issue` 加 `block/block_rq_complete`，按 request 指针配对，在内核侧按 log2 bucket 聚合，用户态周期性拉取 per-CPU map；
- 第二个探针（可选）：major fault（`exceptions/page_fault_user` 里的 major/minor 位）；
- 第三个探针（可选）：`sys_enter_read` 的字节量；
- 有一条观测逻辑必须写进报告：P1 的 preheat 模型下，缓存命中 page cache 时根本不会产生 block I/O——所以 block I/O 直方图天然就能区分命中与未命中；但这里有一个 **readahead 陷阱**：内核预读造成的 major fault 不会记在消费者进程名下，按进程维度归因就会算错。这个陷阱本身就是上等弹药；
- CO-RE：用 `vmlinux.h` 加 bpf2go；优先用 tracepoint、少用 kprobe（ctx 字段在跨版本时更稳）；准备一个降级方案：采样 `/proc/diskstats`，并诚实标注两个口径的差异。

实施步骤

1. 跑 bpf2go 的 hello-world 验证环境 → 2. 做 block I/O 配对延迟直方图加 Go 聚合 → 3.（可选）fault/read 探针 → 4. 把 exporter 接入 P1 实验，与 dataloader 的打点交叉验证口径。

验收标准：在 P1 实验期间能稳定出数；两个口径交叉验证一致；readahead 归因陷阱有专门一节来讲。

弹药：per-CPU map 与 ringbuf 的取舍；为什么 page cache 命中时没有 block I/O；readahead 如何污染进程归因；CO-RE 解决了什么问题。

---

5. S4 bitcask mini 存储引擎（v4：聚焦 WAL/merge/crash recovery，与 P1 正交）

互补关系（v4 核心修正）：P1 用 CAS + **重扫描** 做 crash recovery（重启后扫 `blocks/` 目录，按路径重建索引，~ 分钟级），不做 WAL、不做 merge、不做增量恢复。S4 补的是 **WAL 持久化** + **merge/compaction** + **WAL replay 增量恢复**（重启后 replay WAL 重建索引，~ 秒级），以及 fsync 三档对比、单写多读模型的内存账。

> **面试时的对比故事**："P1 的 CAS 存储层靠重扫描做 crash recovery（实现简单，但重启慢），S4 我用 WAL 做增量 recovery（重启快，但 merge 逻辑复杂）——两种 crash recovery 路径我都实践过，知道各自的适用边界。"

介绍：用 Go 实现一个 bitcask：WAL 加内存索引，加 hint file，加 merge。范围：只做单机；不做：分布式（那部分由 S1 覆盖）、完整的 LSM（与它对读即可）。

关键设计（v4 修改：砍掉与 P1 重合的部分）

> **v4 不再实现**：CAS contentHash 存储层（路径寻址 + 内容哈希摘要）、refcount 引用计数、P2P 块共享——这些是 P1 的东西，S4 不用。S4 用 WAL + CRC 做完整性校验，不做 CAS。

- **WAL 记录格式**（保留 v2）：`crc32 | tstamp(8B) | keysz(4) | valsz(4) | key | value`，tombstone 用 valsz 的特殊值标记（删除操作同样是一次写）；tstamp 统一用 int64 毫秒级（主动在注释里写出"4 字节秒级时间戳有 2038 问题"——小细节，但能留下大印象）；
- **内存索引**：`map[key] → {fileID, offset, size}`；1 亿个 key 的内存账，你要在自己机器上实测出数字（key 平均长度 × key 数量 × Go map 的开销）——这条账决定了 bitcask 的适用边界；
- **活跃文件写满（256MB）之后转为 immutable**；
- **fsync 三档做成配置**：逐条刷盘 / group commit（N 毫秒）/ 只靠操作系统——把三档拿来 benchmark 对比，这是存储引擎最核心的权衡之一；
- **merge**：把 immutable 文件中的存活记录写入新数据文件和 hint file，然后原子切换：先 rename 数据文件和 hint 文件，最后写 manifest 指向新的文件集合；你要把每一个崩溃窗口想清楚，写进注释；
- **读路径**：索引命中之后用 `pread` 读取，再做 crc 校验（校验失败意味着盘上数据腐坏，这时报错或者触发重新 merge）；
- **WAL replay 增量恢复**（v4 强调）：重启时从 manifest 找到最后一次合并位置，replay 之后的 WAL 记录重建内存索引——这是和 P1 重扫描恢复的核心差异。

v3 的四处补强（保留 v3）

1. **时间戳改成 8 字节**：主动在注释里写出这个修正；
2. **benchmark 要打到 10M key 这一档**（32G 内存的机器跑得动）：1M 档算不出 bitcask 的命门——全内存索引的容量账，你必须在 10M 档下实测启动时间、常驻内存、读写吞吐，画出"索引内存/数据量"的比值曲线；
3. **明确实现单写多读模型，并且把它讲透**：写锁天然串行化（这是 bitcask 和 LSM 共同的核心约束），读操作无锁；压测多写者的排队情况和多读的扩展性；

4. **加一次 LSM 对读（不要求实现）**：读 LevelDB/RocksDB 的 compaction 文档，最终目标是能在白板上回答”数据量超过内存之后，bitcask 为什么会输给 LSM（对比 SSTable、稀疏索引、分层 compaction 的读写放大）“。

实施步骤

1. append-only log 加读路径 → 2. 多文件轮转加 tombstone → 3. **启动恢复对比**：先暴力扫全目录，再用 WAL replay，对比两种方式的启动时间（秒级 vs 分钟级）→ 4. merge 加 manifest 原子切换 → 5. 用 fuzz 随机注入 `kill -9`，跑完崩溃矩阵 → 6. benchmark：1M/10M 两档、merge 期间的写延迟抖动（再丑的数字也要敢贴）、写放大计算、fsync 三档对比 → 7. **对比实验**：把 P1 的重扫描恢复数据和 S4 的 WAL replay 数据放在同一张表里，量化两种 crash recovery 的差异。

验收标准：崩溃矩阵全绿；10M 档的容量账有实测；merge 抖动数据完整；**启动恢复时间对比表**有实测；LSM 对读笔记一页。

弹药三件套：- 取舍：WAL replay vs 重扫描（实现复杂度 vs 恢复速度）；merge 原子切换的崩溃窗口；fsync 三档的性能 vs 持久化保证 - 坑：overlayfs 上 O_DIRECT 的坑（和 S2 联动）；merge 期间的写延迟抖动 - 数据：10M key 内存账；fsync 三档吞吐对比；**启动恢复时间对比表**（P1 重扫描 vs S4 WAL replay）

---

6. S6 K8s 调度插件实战：拓扑感知打分（v4：砍阶段 B，聚焦 NFD/topology-updater/拓扑亲和）

互补关系（v4 核心修正）：P1 步骤 7 只做 **数据亲和**（前缀就绪度门控 + 打分 + SchedulingGate），没有 NFD/topology-updater/拓扑约束。S6 补的是 **拓扑亲和**——从硬件拓扑（NUMA/GPU zone）角度做 Filter/Score，和 P1 的数据亲和是正交的两个调度维度。

> **面试时的对比故事**：“P1 做了数据亲和调度（前缀就绪度门控 + 打分），S6 我补了拓扑亲和调度——用 NFD 抓 NUMA 拓扑，用官方 NRT 插件做 Filter/Score，然后在 P1 的数据亲和插件上加了一列拓扑维度，做了双目标冲突实验。两条正交的调度维度我都有实践。”

介绍：基于 kubernetes-sigs/scheduler-plugins，跑通官方的拓扑感知调度，在”数据亲和 × 拓扑亲和”的冲突点上做增量实验。绝对不要声称”我发明了拓扑调度器”，官方 NRT 插件就是你的对照组。

范围（v4 修改）：- **阶段 A**（保留，独立工期 ~1 周）：部署 NFD + topology-updater + 官方 NRT 插件全链路 - **阶段 B**（砍掉）：自研最小 PreFilter + Score 插件——和 P1 步骤 7 的数据亲和插件完全重复（P1 步骤 7 已经写了更完整的版本：数据亲和 + SchedulingGate + 门控 + 降级），再写一遍是重复劳动 - **阶段 C**（保留，与 P1 步骤 7 合流，不额外占工期）：双目标冲突实验

事实前提（保留 v3 不变）

- 官方已经提供 `NodeResourceTopologyMatch`(Filter)加 `NodeResourceTopologyResourceAllocationScore`(Score)，它们消费 `NodeResourceTopology` CRD (KEP-119)，由 NFD (Node Feature Discovery) 加 topology-updater 负责上报；
- Topology Manager 从 k8s 1.27 开始 GA；
- DRA 在今天已经是既成事实，不要再把它当成”未来趋势”来讲：Dynamic Resource Allocation 从 Kubernetes v1.35 开始 GA（stable，特性门控锁定且不可关闭，v1.30 首次引入）；v1.36 (2026-05) 进一步把 ResourceClaim 接入了新的 Workload/PodGroup（内核 gang scheduling 加 topology-aware scheduling）体系。但 2026 年的现网现实是：NRT 插件仍然是主流，各厂商的 DRA driver 生态还处在迁移期——所以 S6 正确的叙事是”亲手实现旧设备模型，同时讲清新世界如何取代它”，两边的功夫都要硬。

DRA 白板要点（不写代码，与阶段 A 同期写半页笔记）

下面四条你必须能脱稿讲清楚：1. 旧 device plugin 模型的痛点：设备被抽象成整数资源（比如 `nvidia.com/gpu: 1`），你无法按显存、型号或互联拓扑发出结构化请求，它不支持设备共享，也不支持按属性表达式过滤，拓扑信息只能走 Topology Manager + NFD + NRT 这条外挂链路；2. DRA 的四个核心对象（`resource.k8s.io/v1`）：驱动用 ResourceSlice 上报设备能力与拓扑，集群管理员定义 DeviceClass（可以类比 StorageClass），工作负载用 ResourceClaim / ResourceClaimTemplate 申领设备（体验类似 PVC/PV 的申领），调度器据此做结构化匹配，kubelet 与驱动之间完成分配握手；它支持 CEL 属性过滤和设备共享；3. 它与 S6/NRT 的关系：DRA 让设备拓扑成为调度器可以直接消费的结构化属性，长期来看会收编 NFD+NRT 这条外挂链路的一部分；但迁移期两套机制并存，NRT 插件在现网中仍被广泛部署——你能讲清”哪部分会被取代、哪部分（NUMA/CPU 亲和）仍会独立存在、迁移卡在哪里（驱动成熟度与存量集群版本）“，才是满分答案；4. 前沿联动：v1.36 的 Workload/PodGroup API 在内核里做 gang scheduling 加 topology-aware scheduling，并且接入了 DRA——这与 P1 的训练 Job 调度、S6 的拓扑亲和是同一个演进方向，面试时可以当作”我在跟踪内核调度演进”的谈资，但明确不跟进实现。

硬件诚实清单（开工第一件事）

先跑一次 `numactl -H` 确认：游戏本的消费级 CPU 几乎肯定是单 NUMA 节点，也没有多 GPU；所以所有拓扑都用 fake/annotation 驱动来开发——这完全正当，官方插件自己的 e2e 测试也在 mock NRT 对象；真机多 GPU 拓扑只在 P2 租云主机拿真值的那个窗口顺带读一次（`nvidia-smi topo -m`），不值得为它单独开预算。

阶段 A：现勘并跑通官方链路（约 1 周，v4 保留）

1. 搭好 kind 集群（版本对齐 scheduler-plugins 的兼容矩阵），按仓库 Developer Guide 在本地构建镜像（kind load）或者直接用发布的 chart；
2. 部署 NFD 加 topology-updater，生成真实的 `NodeResourceTopology` CR；在单 NUMA 机器上手写一份 fake NRT yaml（构造双 NUMA、fake GPU 资源池），作为第二个数据源；
3. 配置 v1 版本的 `KubeSchedulerConfiguration`：包括 profiles（schedulerName）、plugins（在 filter/score 上启用 NRT 插件）、pluginConfig（scoringStrategy：MostAllocated、BalancedAllocation、LeastAllocated 各跑一遍，观察决策差异）；
4. 部署若干请求 CPU/GPU 的测试 Pod，验证绑核与拓扑决策是否符合预期，抓取调度日志；
5. 精读：官方 Score 插件源码（分数如何由 NRT 的 zones 和资源分配算出、如何归一化）、NRT CRD 的字段语义；
6. **验收标准**（你能口述全链路）：device plugin 的 TopologyInfo → kubelet Topology Manager（与 CPU Manager 协同）→ NFD topology-updater → NRT CRD → 调度插件 Filter/Score → bind；
7. **风险保护**：如果一周之内官方全家桶部署不成功（NFD 组件多、镜像拉取坑也多），S6 立即降级为”手写 NRT yaml + 只部署插件本体”；再不行就降级为”纯跟读源码 + 写决策日志推演笔记”，不能让环境黑洞吃掉第二周。

阶段 B：自研最小插件（v4 砍掉，理由见上）

> **v4 为什么砍掉阶段 B**：P1 步骤 7 要写的调度插件比 S6 阶段 B 的”最小件”还完整——P1 有数据亲和 + SchedulingGate + 门控 + 降级，S6 阶段 B 只有拓扑亲和的最小件。做了 P1 步骤 7 之后，再做 S6 阶段 B 等于再写一遍同一个 framework 的同一种插件，只是打分公式换成另一种。面试时只能讲”我写过两个调度插件”，讲不出差异。

阶段 C：双目标冲突实验（1-2 周，与 P1 步骤 7 合流，不额外占工期，v4 保留）

1. 让两个 Score 维度并存：**数据亲和分**（P1 的 Job 子集 readyRatio，由 P1 的 informer 缓存提供）× **拓扑亲和分**（S6 的 fake NUMA/GPU zone 匹配度，由 S6 阶段 A 的 NRT CRD 提供）；
2. 构造冲突场景：Job 的热分片缓存在 NUMA-A 节点上，但空闲 GPU 在 NUMA-A’（拓扑上靠近远端内存）；或者另一个节点 NUMA 局部性很好，但数据是冷的；

3. 权重 w 从 0 扫到 1，画出权重-调度决策曲线，以及对应的 makespan/拓扑惩罚代理指标；
4. 把终点问题写成报告：框架级的多插件分数如何归一化（各插件 Score 的值域）、冲突时为什么不存在银弹、生产环境中应该让谁把权重暴露给用户；
5. 合流动作：**S6 的拓扑亲和 Score 直接作为 P1 步骤 7 调度插件的第二个 Score 维度**——P1 仓库里保留完整的双维度插件，S6 仓库里保留阶段 A 的部署脚本、阶段 C 的实验报告和权重扫描曲线；
6. **验收标准**：产出一张冲突权重-决策曲线图；DRA 四条白板要点能脱稿讲（见上，包含 v1.35 已 GA 的现状判断，禁止再说”DRA 是未来的实验特性”）。

弹药三件套

- 取舍（**v4 修改**）：NRT annotation fake 与 NFD 全家桶之间怎么选、双目标如何归一化、**为什么阶段 B 被 P1 步骤 7 覆盖了**（体现你能识别重复劳动、主动优化）
- 坑：KubeSchedulerConfiguration 的 apiVersion、多 profile、schedulerName、RBAC 权限、kind 镜像加载
- 数据：权重-决策曲线加 scoringStrategy 对照

诚实清单：拓扑全部是 fake 的；官方 NRT 插件是基线，不是要打倒的对手；没有做绑核验证，也没有真机性能数据；DRA 没有动手实现，但它的事实状态（v1.35 GA）和四个要点你必须跟到能讲、能回答迁移期共存问题的程度。

---

7. S7 mini KV Cache Manager（v4 新增，P2 互补）

互补关系：P2 把 vLLM 当黑盒用（只消费 KV 事件，不自研 KV block 管理）。S7 补的是 **引擎内核视角**——精读 vLLM 的 `block_manager.cpp` 之后，用 C++ 写一个简化版 block manager，管理固定大小的 KV cache blocks、LRU 驱逐、prefix lookup、capacity 动态调整。

> **面试时的对比故事**：“P2 是网关视角看 KV cache（消费引擎推的事件），S7 是引擎内核视角看 KV cache（自己管理 block pool、驱逐、prefix 匹配）——两种视角我都有实践，知道引擎内部和网关之间怎么协作。”

时间盒：2-3 周（和 P2 步骤 4 并行）

前置：S2 的 C++ 系统编程经验（io_uring / O_DIRECT 之后你对 C++ 内存管理更熟了）、M5 的 vLLM 源码精读笔记（先读再写）

范围：做 block pool、LRU 驱逐、prefix lookup；不做：真正的 vLLM 内核、CUDA 代码、continuous batching 调度。

vLLM 内核精读（前置，M5 联动）

精读 vLLM 源码的三个核心文件（用 vLLM v1.x 锁定版本）：1. `vllm/v1/core/kv_cache_manager.py`（或 `vllm/vllm/v1/worker/gpu_model_runner.py` 里的 block manager）：KV block 的分配、释放、淘汰、prefix cache 索引 2. `vllm/attention/backends/paged.py`：paged attention 的内存布局（每个 block 多大、token 怎么映射到 block）3. `vllm/vllm/v1/core/scheduler.py`：continuous batching 调度时 KV cache 怎么被引用和释放

产出一篇《vLLM KV Cache 内核对读笔记》——重点记录三个问题：- block 是多大？token 怎么映射到 block index？- LRU 驱逐时怎么判断”这个 block 还能不能被某个 in-flight 请求引用”？- prefix cache 的索引结构是什么？怎么判断”新请求的前缀命中了缓存里的哪些 block”？

C++ 简化版实现

精读完 vLLM 内核后，用 C++（C++17，不用 CUDA，跑在 CPU 上）写简化版 block manager：

核心数据结构：- `Block`：固定大小（默认 16 blocks/页，可配置），每个 block 存一段 token 的 KV 数据（简化为固定大小的 buffer，不需要真 FP16/BF16 数据）- `BlockPool`：`vector<Block>`，固定容量，初始化时全部标记为 free - `PrefixIndex`：`map<BlockHash, vector<BlockID>>`——block 哈希（前 256 token/block 的递归哈希）到持有该 block 的 ID 列表 - `LRU`：`list<BlockID>` + `unordered_map<BlockID, list::iterator>`

核心接口（伪代码）：

```
class KVCacheManager {
public:
    // □ pool □□□ n □□□ block□□□□ free list □□□□
    vector<BlockID> AllocBlocks(int n);

    // □□□□ block □□□ request □□□in-flight□□□□□□
    void RefBlocks(const vector<BlockID>& blocks, RequestID req);

    // request □□□□□□□□□□□□□□□□□□□□ free list
    void UnrefBlocks(const vector<BlockID>& blocks, RequestID req);

    // LRU □□□□ tail □□□□□□□□□□□□ block
    // □□□□□□□ block □□
    int EvictLRU(int n);

    // prefix lookup□□□□□□□ block hash □□□□□□□□□□□□□□□□□□
    // □□□□ block hash □□□□□□□□ PrefixIndex □□□□□□□□□
    int PrefixHitDepth(const vector<BlockHash>& req_block_hashes);

    // □□□□□□□□□□□□ host memory □□□ block□□□□□□□□□□□
    void ResizePool(int new_capacity);
};
```

关键设计：- **BlockHash 对齐**：和 vLLM 一样，按前 ~256 token 一个 block 的粒度做递归哈希 `h_i = H(h_{i-1} ‖ token_i)` - **in-flight 引用计数**：每个 block 有一个 `ref_count`，> 0 时 LRU 跳过；这是 vLLM 驱逐时不驱逐活跃请求 block 的核心机制 - **PrefixHitDepth 语义**：从第一个 block hash 开始连续匹配，断开后不计入（和 P1 的 prefixLen 语义一致，vLLM 也是这么做的）- **线程安全**：用 `shared_mutex`——读路径（PrefixHitDepth）用读锁，写路径（Alloc/Ref/Unref/Evict）用写锁

实验与对读

实验（和 P2 的负载台联动）：1. **LRU 驱逐曲线**：固定 pool 容量（比如 1024 blocks），用 P2 的负载台 trace 跑 1000 个请求，记录：驱逐命中率（被驱逐的 block 之后是否被重新引用）、in-flight block 占比随时间变化、prefix hit depth 下降曲线 2. **Prefix lookup 精度**：构造三种场景（全命中、半命中、全 miss），对比简化版和 vLLM 真实实现的 prefix hit depth 数值——简化版的 hash 算法和 vLLM 不一样，所以数值会有差异，但**曲线形状应该一致**（共享前缀比例越高，prefix hit depth 越高）3. **Capacity 动态调整**：模拟弹性伸缩——pool 从 512 → 1024 → 512 → 2048，观察驱逐和 prefix hit depth 的响应

工业对读（必做）：精读 vLLM 内核里的驱逐逻辑——重点看它怎么处理”这个 block 还在 in-flight 请求里但又没被显式 ref”的边界情况。你的简化版用显式 Ref/Unref 处理，vLLM 内部是怎么处理的？差异有多大？

验收标准

- Block pool 全功能可用（Alloc/Ref/Unref/Evict/PrefixHitDepth/Resize）
- LRU 驱逐曲线 + prefix lookup 精度对比 + capacity 调整曲线三张图
- 《vLLM KV Cache 内核对读笔记》写完，能讲清楚简化版和 vLLM 内核的 3 个核心差异

弹药三件套：- 取舍：为什么 vLLM 用显式 ref_count 管理 in-flight block（而不是靠 GC 或所有权）；PrefixHitDepth 的语义为什么是连续匹配而不是覆盖率 - 坑：vLLM v1.x 的 block manager 接口和 v0.x 完全不一样（v0.x 用 `BlockTable` 二维数组，v1.x 用 `BlockPool + Index`），**版本锁定是第一天就要做的事** - 数据：LRU 驱逐命中率曲线；**简化版 vs vLLM 内核差异对照表**

---

8. 微弹药 M1-M5（按天计的练手小品，算不上项目）

M1 mini-container（必做，1-2 天） 性价比最高

互补关系：大项目只用 K8s API，不碰容器底层——M1 补的是 namespace/cgroup/pivot_root 的底层手感。

做什么:用 Go(或者直接用 C 调 `clone`)写一个 100-200 行的容器运行器。- 用 `clone` 加 `CLONE_NEWPID/NEWUTS/NEWNS`(有余力再加 `NEWNET/NEWUSER`);- cgroup 用 v2:在 `cgroup.controllers` 体系下写 `cpu.max`、`memory.max`、`memory.swap.max`，把子进程的 pid 写入 `cgroup.procs`; - rootfs 用 busybox 或 distroless 的根目录，调用 `pivot_root`（入门版可以先用 `chroot`）切换，再挂载 `/proc`、`/tmp`; - stretch（可选）：用 overlayfs 的 lower/upper/merged 做一个可写层——这正好与 S2 里" overlayfs 上 O_DIRECT 的坑" 呼应。

验收标准：容器内执行 `ps` 只能看到自己的进程树；hostname 相互独立；把 `memory.max` 设成 64M 后跑内存分配，能触发 cgroup OOM 并观察宿主行为；用 `lsns` 能看到新的命名空间。

你必须能讲：容器为什么不是虚拟机（共享宿主内核意味着什么、攻击面在哪里）；cgroup v2 相对 v1 的统一层级变化；pivot_root 与 chroot 的区别；为什么 user namespace 是 rootless 容器的关键；containerd/runC 在 K8s 链路中的位置（kubelet → CRI → containerd → runC）。

降级路径：`pivot_root` 卡住就退回 `chroot` 加 mount namespace，核心目标（找到 namespace/cgroup 的手感）不打折。

M2 mini-CNI（平台/网络向，1-2 天）

互补关系：大项目只管容器调度（S6）和挂载（P1），不管 Pod 网络——M2 补的是 bridge/veth/地址池/路由这套 Pod 网络的底层。

做什么：写一个能被 CNI 规范真正调用起来的最简网络插件（Go 可执行文件）。- 实现 CNI spec 的 ADD / DEL / CHECK 三个命令：从 stdin 读 NetConf JSON，从 `CNI_ARGS` 和环境变量里拿 netns 路径; - bridge 模式：建好 bridge，给容器 netns 创建 veth pair 并把一端塞进去，从 `/24` 地址池（用位图或租约文件持久化，防止 ADD 重启之后地址泄漏）分配 IP，配好接口地址与默认路由，再把 lo 拉起来; - 用 `cnitool` 在两个独立的 netns 上验证互通；DEL 时释放 IP、删掉 veth。

验收标准：两个 netns 之间能 ping 通；重复 ADD 不会撞 IP；DEL 之后地址正确回收；用 `tcpdump` 能抓到 bridge 转发的包。

你必须能讲：K8s 的" IP-per-pod" 网络模型；CNI 在容器创建链路中是哪个时刻被调用的（netns 已经建好、rootfs 已经就位之后，由运行时/CRI 调用）；跨节点流量怎么办（VXLAN、路由、BGP——这个练习故意不做，但你要能说清边界在哪里）；service 的 iptables/IPVS 与 CNI 为什么是两层东西。

降级路径：如果 CNI 调试吃掉了半天还没结果，就停下来，改为”读 containernetworking/plugins 的 bridge 插件源码，再用 `ip link/addr/route` 手敲复现全链路”，然后写笔记。

M3 mini-CSI（存储/数据流向，2-3 天） 与 P1/S4 咬合最紧

互补关系：P1 用 hostPath 只读挂载（preheat 模型），S4 是单机存储引擎——M3 补的是 CSI 标准 API，让你知道”把宿主目录挂到 Pod 上，K8s 标准流程是什么样的”。

做什么：写一个最小的 CSI 驱动，让它真的被 kubelet 调起来，让 Pod 能挂载你提供的卷。- 实现三个 gRPC service：Identity（GetPluginInfo/Capabilities/Probe）、Controller（最小实现，先不做 provisioning）、Node（在 NodePublishVolume 里把宿主目录 bind mount 到 kubelet 给的 target path；在 NodeUnpublishVolume 里反向卸载）；- 走 kubelet 的 plugin registration 机制：在 `/var/lib/kubelet/plugins_registry/` 暴露注册 socket，与 kubelet 完成握手（这一步本身就是最有价值的弹药）；- 先打通 static PV 加你的 CSI driver 的绑定挂载闭环；stretch 目标：实现 CreateVolume/DeleteVolume（在宿主上建/删目录）加 StorageClass 动态供给；- 在 kind 里可以用 DaemonSet（privileged、挂 hostPath）部署，也可以直接作为节点进程跑，两种形态里选简单的一种先跑通。

验收标准：PVC 完成绑定 → 测试 Pod 挂载成功并能读写文件 → 删掉 Pod/PVC 之后 bind mount 被干净卸载（用 `findmnt` 验证没有残留）。

你必须能讲：CSI 三段式流程——Attach（ControllerPublish）、Stage（NodeStageVolume，块设备格式化并挂到全局挂载点）、Publish（bind mount 到 Pod）各自解决什么问题，为什么你的最简实现只需要 Publish；kubelet registration 握手与 socket 的生命周期；ephemeral 卷与 persistent 卷的区别；Fluid/JuiceFS 为什么需要自己的 CSI driver（FUSE 挂载如何经由 CSI 注入 Pod）——最后这一问直接和 P1 现勘连起来。

降级路径：动态供给做不完就停在 static PV 闭环（80% 的弹药已经到手）；在 kind 里注册不上，就在节点上用 csc 工具直接调你的 gRPC 方法来验证。

M4 vLLM token 级 profiling（v4 新增，P2 互补，1-2 天）

互补关系：P2 只有 vLLM /metrics 的**粗粒度**指标（TTFT/TBT/吞吐/前缀命中率）——M4 补的是 **token 级**观测，能看到每个 token 的 prefill/decode 时间、prefix hit/miss 精确到 token 位置。

做什么：用 eBPF uprobes + Python 对 vLLM 做 token 级 profile。- 用 `bpftrace` 或 `bcc` 的 uprobes 挂在 vLLM 的 Python 函数上（比如 `vllm/v1/core/async_scheduler.py` 里的 `schedule()` 方法、`gpu_model_runner.py` 里的 `execute_model()` 方法），或者用 `perf` 记录函数调用时间；- 对每个请求记录：每个 prefill chunk 的耗时、每个 decode step 的耗时、哪个 replica 做的、prefix hit depth 精确到 token 位置；- 用 Python 脚本解析采样数据，产出：**每个 token 的 prefill/decode 时间分布图**、**prefix hit/miss 的 token 位置热力图**、**preemption 发生在哪个 token 位置**。

> **不依赖 GPU**：如果当前是 CPU 后端的 vLLM，直接跑 uprobes；如果是 GPU 后端，用 uprobes 挂在 host Python 函数上（不需要挂 GPU 内核）。

和 P2 的联动：P2 的 TTFT/TBT 是”整个请求的聚合指标”，M4 是”每个 token 的拆解指标”——当 P2 的 TTFT 异常高时，用 M4 可以定位是”某个 prefill chunk 特别慢”还是”prefix miss 导致 prefill 重新计算”。

面试时能讲：> “P2 用 vLLM /metrics 看 TTFT/TBT 的粗粒度指标，我用 eBPF uprobes 做了 token 级 profiling——能看到每个 prefill chunk 和 decode step 的时间分布、prefix hit 精确到 token 位置。这个工具帮我定位了一次 TTFT 尖峰是因为 preemption 正好发生在 prefill chunk 边界，导致重新计算了 512 个 token 的 KV cache。”

M5 vLLM 引擎源码精读笔记（v4 新增，P2 互补，1-2 天）

互补关系：P2 消费的是 AIBrix 路由层源码（Envoy plugin / Go router），没有读 vLLM 引擎内核——M5 补的是 vLLM 引擎核心的 C++/Python 源码精读，和 S7 联动（S7 是" 读完之后写简化版"，M5 是" 精读之后写笔记"）。

做什么：精读 vLLM 源码的三个核心文件（用 vLLM v1.x 锁定版本），产出一篇半页笔记：1. **block_manager**：KV cache block 的分配/释放/淘汰/前缀索引——重点回答" vLLM 怎么判断这个 block 还能不能被 in-flight 请求引用"、"前缀命中深度是怎么从 block hash 链算出来的"2. **scheduler**：continuous batching + chunked prefill + preemption 的调度逻辑——重点回答" vLLM v1 怎么平衡 prefill 和 decode 的 GPU 时间"、"preemption 怎么选被驱逐的请求" 3. **attention**：paged attention 的内存布局——重点回答" 为什么 paged attention 要把 KV cache 分成固定大小的 block（比如 16 blocks/页）"、" token id 怎么映射到 block index"

和 P2 的联动：P2 的核心 2（弹性伸缩）需要理解" 新副本需要预热多少 KV block 才能有意义地接受流量" ——M5 的笔记里能找到 block 粒度和 prefix 命中深度的关系，直接给预热策略提供参数。

面试时能讲：> "P2 是网关视角看 KV cache 路由，我精读了 vLLM 引擎内核的 block_manager、scheduler、attention 三个核心模块——知道引擎内部怎么管理 KV block、怎么做 continuous batching、paged attention 的内存布局是什么样的。这让我能在路由层正确地消费引擎推的 KV 事件，也让我能理解为什么 PegaFlow 这种外部 KV cache 服务能工作。"

---

9. 微弹药与面试域的关系（v4 扩展）

微弹药	覆盖的面试域	联动
M1	容器运行时、namespace/cgroup、CRI 链路	S6（K8s 的下层）、S2 的 overlayfs 坑
M2	CNI、容器网络模型、netns	S6 调度之后" Pod 如何落地并联网"
M3	CSI、kubelet 卷生命周期、存储编排	P1 现勘（Fluid/JuiceFS CSI）、S4 存储岗叙事
M4	eBPF uprobes、token 级观测、profiling	P2 的 TTFT 归因、S7 的 token 级对比
M5	vLLM 引擎内核、block_manager、scheduler、attention	S7（简化版 KV manager 的设计依据）、P2（引擎内核视角）

---

v4 定稿 *2026-10-15*，*v4.1* 砍 *S8 +* 删完成顺序/砍项清单 定稿 *2026-10-15*