议题 6 报告：AI Infra 就业前景与赛道比较

> 口径说明：本报告为 2026-10 定性判断，基于导师存量行业认知；所有涉及具体薪资、HC 数量、转正比例的数据均为**方向性刻画**，需在 2027 年投递窗口前做市场快照现查（议题清单已挂”需现查”项）。学员画像输入：985（末流）本科、2028 届、零实战起点、全职冲刺一年+、大四实习半年计划、技能栈 Go + K8s + 分布式存储。

---

1. 模型厂自建 Infra 到底有多难

模型厂 infra 对你来说是一张值得买的彩票，不要为它改变主策略。这个判断基于四个独立因素叠加，属于诚实评估。

1.1 HC 极度稀缺，且大量名额内部消化

头部模型厂（月暗、DeepSeek、MiniMax、智谱、百川、阶跃一类）的 infra 校招 HC 通常在个位数到极小两位数量级。这个池子小到什么程度：一个组当年可能只放 2-5 个校招名额，其中相当比例（方向性观察，约三成到一半）在实习转正阶段就内部消化了，留给社会投递的真正”空位”可能只剩 1-3 个。你面对的是概率门槛，能力到线了也未必轮得到。

1.2 同池候选人画像偏重，你的简历要靠硬证据绝对质量

和你同池竞争的人主要是：顶尖院校硕博、ACM/系统竞赛获奖者、顶会论文作者、已经在同类公司完成过 infra 实习的人。你作为末流 985 本科，简历关能不能过，取决于硬证据的绝对质量（项目深度、开源贡献、实习经历），相对排序是次要因素——这意味着你必须在三个维度上都做出真东西，才可能被捞进面试。

这里有一个对你有利的结构：infra 岗比算法岗更**作品导向**，学历权重相对低。一个本科简历如果挂着”我给 vLLM/JuiceFS/某个 K8s 调度器提过被 merge 的 PR，数据是 X，解决了 Y 问题”，它能过的简历关比同质量的算法简历高得多。这是你这一年冲刺要赌的东西。

1.3 考察深度下探到本科课程体系之外

模型厂 infra 面试常下探到这些方向：内核网络栈（XDP/DPDK）、RDMA 与集合通信（NCCL/RDMA Verbs）、CUDA 层、分布式一致性的工程取舍（Raft/线性一致性场景下的工程妥协）、推理引擎内核（PagedAttention、连续批处理、KV Cache 量化）。这些方向你的 P1（TrainCache）和 P2（KVRouter）会刻意覆盖到一部分，但一年冲刺能达到的深度是”能聊清楚原理、能讲明白取舍”，达不到”能改其内核”的程度。模型厂校招对本科生的预期也是前者，不是后者——这是你能踩到的格子。

1.4 入场券结构：三件套缺一不可

拿到模型厂面试的最低配置大概是：硬核项目（有真数据、有防御力）+ 可验证的开源贡献 + 一段相关实习。这三件你现在都是零——这正是你这一年冲刺的全部意义。三件套里任何一件缺失，模型厂简历关都难过。

1.5 一句话定性

模型厂之难，难在 HC 稀缺导致的排序竞争。同能力 profile 的人去投算法岗，简历直接死；去投 infra 岗，能进面但排序靠后。这个差异本身就是赛道价值的一部分——你押 infra 的护城河，就建立在这个差异上。

---

2. 你应该主力追求什么、尝试触碰什么

把目标公司分层来看。这里的”层”是精力分配建议，没有价值判断含义。

2.1 主力层（简历主战场，精力大头）

云厂商 AI Infra 平台岗： - 阿里云 PAI（机器学习平台）、ECU 灵骏（智算集群）、文件存储 NAS 与 CPFS（AI 存储）、容器服务 ACK - 火山引擎（字节）：机器学习平台、AI 推理服务、云原生计算 - 腾讯云：TI 平台、星星河（智算）、对象存储与分布式文件 - 华为云：ModelArts、IEF（智能边缘）、OBS 与 SFS

大厂基础架构部门： - 字节：基础架构（CloudOS、存储、容器）、AML（应用机器学习平台） - 阿里：基础设施（佳池、存储、计算平台）、PAI - 腾讯：云架构、TEG 存储与计算 - 华为：2012 实验室、云底座

这类岗位的特点是：HC 总量是 infra 赛道里最大的一档；JD 与你的技能栈完全对口（Go/K8s/分布式存储/KV Cache/调度）；985 本 + 系统层项目是**达标线以上**配置，不是减分项。

2.2 认真投层（正常预期，保底面）

中大型互联网公司的存储/K8s/平台岗：美团、京东、网易、快手、滴滴的基础架构与存储团队；运营商云（移动云、天翼云、联通云）的 AI 平台组；新兴 AI 公司（商汤、旷视、第四范式、零一万物、Minimax 之外的若干家）的平台/serving 组。

这类岗位决定你”有没有 offer”，是兜底的基本盘。它们的 JD 关键词和主力层高度重叠，同一份简历变体可以双投。

2.3 彩票层（尝试触碰，成本受控）

模型厂自建 Infra（月暗、DeepSeek、MiniMax、智谱、阶跃、百川）；数据库厂商内核岗（OceanBase、PolarDB、GaussDB、TiDB——你的 S4 存储引擎项目是这些岗位的入场券）；推理服务创业公司（SiliconFlow、潞晨、后起的一批）。

投递成本接近零（同一份 V1/V2 变体即可），面试经验本身有价值。**不为这一层改变项目节奏**——你的 P1/P2 主线要服务主力层，彩票层是顺带投。

2.4 不投入层

算法岗（训练/对齐/应用算法岗）。转行成本最高、赛道最卷、与你全部积累无关。详细劝退理由见 §10。

---

3. 这一行就业前景的总体判断

AI Infra 是一个”窄而深”的赛道：HC 总量不如应用层，但供需比、护城河、抗周期性是所有技术赛道里最优的一档。

3.1 供需结构对你有利

校招 HC 总量不大，但竞争者同样稀少。大部分 CS 毕业生涌向后端与算法，系统层候选人长期稀缺。供需比（候选人 ÷ 岗位）是所有技术赛道里最好的一档——你作为系统层候选人，稀缺性本身就是议价权。

3.2 三年窗口判断（2026→2028）

- 推理商用化扩张期：serving/网关/调度层需求增速高于训练侧；
- Agent 应用爆发期：网关与多租户调度需求外溢到应用层公司；
- 训练侧进一步向少数大厂集中：训练 infra 岗位地域和公司分布收窄。

你押的推理方向 + Go 栈，恰好踩在增量最大的格子上。如果你押训练侧，2028 年的地理选择会比现在窄。

3.3 长周期判断

infra 技能随年限增值，系统功力是复利资产。这与算法层”知识半衰期极短”形成对照——算法层一年不学就落后，infra 五年前的 Raft/GC/网络栈知识今天还在用。十年周期看，infra 的复利性比算法层强得多。

3.4 风险情景（AI 降温）

如果 AI 降温，存储底座依然存在（数据必然存在），且存储行业自身的增长段恰恰是 AI 存储。你的融合背景在存储行业内部同样是差异化。fallback 叙事见学员档案。

3.5 代价要诚实

岗位地域高度集中（北上深杭，成都次之）；工作性质偏深偏”闷”，曝光度与叙事性不如算法/产品岗；总盘子小意味着”选错城市/选错公司”的调整成本高——infra 圈子比后端圈子小，跳一次错的代价比后端大。

---

4. 三类雇主的具体差异

主力层+彩票层涉及三类雇主：云厂商、大厂基础架构、模型厂/数据库厂。这三类的面试风格、技术栈、成长路径、转正机制都不一样，需要分别准备。

4.1 云厂商（阿里云/火山/腾讯云/华为云）

- **面试风格**：重视工程落地与稳定性经验，会问线上故障复盘、容量规划、SLO 设计。八股偏 K8s/容器/存储原理。
- **技术栈**：Go 为主，K8s 生态（Operator/Controller/调度插件）、存储引擎、分布式系统。Python 用于工具链。
- **成长路径**：从 P5/P6（应届）到 P7/P8 走技术专家线或架构师线；3-5 年内能主导一个子系统。
- **转正机制**：暑期实习转正比例方向性观察在 40-70%，转正后直接进校招体系，薪资按校招 band。
- **HC 规模**：infra 赛道里最大的一档，单部门校招 HC 常在两位数到小三位数。

4.2 大厂基础架构（字节/阿里/腾讯的基础架构与存储）

- **面试风格**：偏底层原理与系统设计，会下探到内核（网络栈/文件系统/GC）、分布式一致性、性能优化。八股偏操作系统+网络+分布式。
- **技术栈**：C++ 与 Go 并重，底层组件多为 C++，上层平台多为 Go。你的 C++ 薄弱在这里是劣势，需要 S2/S4 铺路补齐。
- **成长路径**：走技术专家线，资深后能主导核心组件；转岗灵活性高（基础架构内部流转）。
- **转正机制**：暑期实习转正比例方向性观察在 30-60%，因部门而异。
- **HC 规模**：单部门校招 HC 在小两位数到中两位数。

4.3 模型厂/数据库厂（彩票层）

- **面试风格**：偏深度原理与前沿跟踪，会问最新论文、训练/推理最新工程实践、底层优化。考察面比前两类更窄更深。
- **技术栈**：Python+C++ 为主（模型厂），C++ 深度（数据库厂）。Go 在这类岗位权重低，你的 Go 优势会被稀释。
- **成长路径**：扁平、机会密度高、早期员工红利大；但公司存活率参差，平台风险高。
- **转正机制**：实习转正比例方向性观察在 50-80%（HC 本来就少，实习消化比例高）。
- **HC 规模**：infra 赛道里最小的一档，单组校招 HC 个位数到小两位数。

---

5. AI Infra 岗位 JD 关键词矩阵（方向性观察）

这是你简历和技能栈要对齐的关键词清单，逐类列：

岗位类型	高频关键词	你的覆盖情况
K8s 平台/Operator	controller-runtime、reconcile、CRD、scheduler framework、informers	P1 P2 完全覆盖
推理服务	vLLM、PagedAttention、continuous batching、KV Cache、Triton	P2 主线覆盖
AI 存储	JuiceFS、MinIO、Alluxio、CPFS、GDS、RDMA、纠删码	P1 主线覆盖
训练数据流	dataset pipeline、sharding、prefetch、checkpoint、dataloader stall	P1 v4 主线覆盖
调度/网关	路由、负载均衡、HPA、KEDA、限流、熔断	P2 部分覆盖，需 S5 补
分布式基础	Raft、Paxos、线性一致性、CAP、分布式事务	笔记层覆盖，需 S2/S4 工程化

这个矩阵是你准备简历变体时的对照表。每一行如果完全空白，对应方向就是你的盲区。

6. 2028 届竞争环境预判

基于 2026 年的市场方向性观察，对 2028 届（你这一届）的竞争环境做以下预判：

6.1 增量利好

- 推理侧岗位继续扩张：2026-2028 是推理商用化主升浪，serving/网关/调度岗位的需求增速是 infra 赛道里最高的一档。
- Go 栈在 AI Infra 的渗透继续：vLLM 周边、Operator 生态、网关层越来越多用 Go 写，你的主语言红利持续。
- 系统层稀缺性持续：CS 毕业生涌向应用与算法的趋势不会反转，系统层候选人长期稀缺。

6.2 增量压力

- 2025-2026 起的”AI Infra 热”会让 2028 届的 infra 投递人数比 2026 届多——但增量主要来自想转方向的算法/后端同学，他们的系统层积累不如你。
- 模型厂 HC 不一定扩张：模型厂 infra HC 受融资节奏和商业化进度强约束，2028 年具体情况需届时核实。
- 顶校硕博的”AI Infra 视角”投入增加：越来越多的顶校硕博把 infra 当成算法岗之外的备选，他们对你的简历挤压主要发生在模型厂彩票层。

6.3 你的位置

你押的是”本科+系统层深度+推理方向+Go 栈”——这个组合在 2028 届的稀缺度，高于”硕士+算法层+训练方向+Python 栈”。前者稀缺，后者拥挤。你的位置在主力层是达标线以上，在彩票层是排序靠后但有面试机会。

7. 实习转正比例的方向性刻画

实习转正是校招里最关键的”暗坑 HC”——很多岗位的校招名额实际上在实习阶段就发完了。方向性观察：

雇主类型	暑期实习转正比例（方向性）	关键节点
云厂商	40-70%	实习满 8 周可进入转正答辩，答辩后 1-2 周出结果
大厂基础架构	30-60%	转正受部门 HC 强约束，部分部门当年无校招 HC 则不转
模型厂	50-80%	HC 少但实习消化比例高，转正谈判空间小（HC 就那么多）
中大型互联网	30-50%	转正机制相对透明，部分公司有明确的实习评级体系

含义：你 2027 暑期实习的转正结果，可能直接决定你秋招的主战场——如果实习公司给了满意 offer，秋招就只投彩票层+更心仪的主力层；如果没给或给的不满意，秋招全量投。这就是”边实习边秋招”策略的真正价值。

---

8. 相关赛道对比（非 AI Infra 但可迁移）

如果你在投递季想留 fallback，这些赛道和你的技能栈高度重叠：

- **分布式存储/数据库内核**：你的本命方向。OceanBase/PolarDB/GaussDB/TiDB 一类，C++ 权重高，需要 S4 铺路。HC 比 AI Infra 略多，赛道更老更稳。
- **云原生平台（K8s 生态）**：和你的技能栈零差异。各大云厂商的容器服务团队、独立 K8s 创业公司。HC 中等，但岗位叙事性弱于 AI Infra。
- **通用 Go 后端**：降维打击。任何互联网公司的后端都能投，HC 最大但与你的深度积累不匹配。
- **数据库中间件/缓存**：Redis、Pika、Vearch 一类。和你的存储背景部分重叠，HC 小。

这些赛道的存在意味着你的迁移成本极低。你的位置是全行业迁移成本最低的节点之一，向外每一步都通向可就业面；别人要从外部挤进你这个位置，难度大得多。

---

9. 你自身的迁移成本表

```
AI Infra ──→ 云原生平台          零成本（同一技能栈）
         ──→ 分布式存储          低（本命方向，只差产品域知识）
         ──→ 通用 Go 后端        低（降维）
         ──→ 数据库/存储内核     中（需补 C++ 深度 → S2/S4 即在铺路）
         ──→ 推理引擎内核        高（需 CUDA/C++/Python 深度，非本科阶段目标）
反向：算法 → Infra                难（系统工程功力无法速成）——你的护城河所在
```

这张表给你两个东西：安全感来源，和面试叙事资产。面试官问”为什么不投算法”，你的答案就是这张表的反向那一行。

---

10. 赛道比较：AI Infra vs 算法层 vs AI 应用层 vs AI 产品经理

维度	AI Infra	算法层（训练/对齐/应用算法）	AI 应用层（Agent/应用后端）	AI 产品经理
校招 HC	中（窄赛道）	收缩中，头部化	大	少，且偏好硕士/有作品
竞争烈度	**低（系统性稀缺）**	极高（最卷）	高（与后端人流重叠）	中高
学历敏感度	中（作品导向）	**极高（顶校硕博起步）**	中	中高

维度	AI Infra	算法层（训练/对齐/应用算法）	AI 应用层（Agent/应用后端）	AI 产品经理
对 985 本科友好度	**较高**	基本关门（个例不可复制）	高	低
护城河/可积累性	**深（随年限复利）**	浅（知识半衰期短）	浅-中（工程重复度高）	中（依赖平台与行业）
薪资水平	高（接近算法）	最高	中高	中高
抗周期性	**最强（底座属性）**	弱（随热点波动）	中	弱
与你的技能栈匹配	**完全匹配**	不匹配	匹配但浪费深度	完全不匹配
你的转出/转入成本	极低转出	转入成本最高	转入即降维	转入需重起炉灶
主要劣势	总量小、偏深偏闷、地域集中	卷、学历墙、知识贬值	可替代性高、深度浅	应届坑位少、看背书

逐赛道点评

- **算法层**：唯一需要明确劝退的选项。三个硬约束对你同时成立：学历墙（985 本在简历关系统性劣势）、转行成本（你的一年要用来补算法，infra 积累全部作废）、知识贬值（护城河最浅）。个别”本科生卷赢算法岗”的案例存在，但那是幸存者叙事，不能作为策略。
- **AI 应用层**：能就业，门槛友好；但技术深度浅、可替代性高，长期和传统后端在同一池子里竞争。你的项目深度放在这里是浪费——除非把它作为 V3 变体的保底出口，否则不主动投入。
- **AI 产品经理**：应届坑位少、重背书与沟通资历、几乎不消费你的技术积累；转行等于放弃全部存量。除非你发现自己真正的兴趣在产品侧（目前所有证据都相反），否则不讨论。

---

11. 时间线上的行动含义

1. **2027 秋的实习窗口决定上限**：实习是所有层通用的硬通货——模型厂的校招名额大量留给实习转正，平台岗的实习经历直接决定校招排序。你”大四实习半年”的计划与 2028 春秋招的衔接是成立的，但 2027 秋投实习时，P1 基座+至少 1 个增量+首批 OSS 记录必须已可见。
2. **母版简历从现在开始攒素材**（议题 4 已定），投递前 4-8 周生成三个变体（V1 主力层、V2 彩票层、V3 保底层）。
3. **彩票层投递不占新精力**：V1/V2 变体直接复用，唯一新增动作是关注模型厂/数据库厂的校招时间点。

---

12. 需现查清单（2027 年投递窗口前执行）

- ☐ 目标公司清单与 2027/2028 届校招 HC、JD 关键词（逐厂核实）
- ☐ 各层薪资 band（白菜/sp/ssp 分位）——方向性观察见 §13，需届时更新
- ☐ 实习转正比例与实习投递时间点（逐厂核实，方向性数据见 §7）
- ☐ 模型厂当年是否开放 infra 校招（逐厂核实，不可假设）

- [ ] 各厂 2027 暑期实习投递开放时间

---

13. 薪资方向性刻画（需届时现查更新）

以下是 2026 年的方向性观察，仅用于建立认知坐标系，不能作为 2028 投递季的决策依据：

层级	白菜档（普通 offer）	SP 档	SSP/天才少年档
大厂基础架构（校招）	25-35w 年包	35-50w	50-80w+
云厂商 AI Infra	22-32w	32-45w	45-70w
模型厂 infra	30-45w（含期权）	45-70w	70-120w+（期权不确定性高）
中大型互联网存储/平台	20-28w	28-40w	40-55w

几个解读要点： - 模型厂现金部分不一定高于大厂，但期权不确定性高，上行空间大，下行风险也大； - SSP/天才少年档对本科开放的比例极低，主要面向顶校硕博或竞赛生； - 你的目标应该锚定 SP 档（主力层），白菜档是兜底，SSP 档是不可控增量。

---

14. 一页结论

> **主力追求**：云厂商 AI Infra 平台岗 + 大厂基础架构岗（V1/V2 简历的主战场）。 **认真投**：中大型公司存储/K8s/平台岗（保底面）。 **尝试触碰**：模型厂自建 Infra、数据库内核岗、推理服务创业公司（彩票，零额外成本）。 **明确放弃**：算法岗、AI 产品经理（与你的积累和护城河全面冲突）。 **总判断**：AI Infra 是窄而深、供需比与护城河最优、且你的全部积累都能复利的赛道；风险情景有实底座 fallback。你唯一要做的，是让 2027 秋实习窗口到来时，硬证据已经摆在那里。